

SVM 的数学推导和 Python 实现

赵新锋

2021 年 7 月 12 日

摘要

支持向量机 (support vector machines, SVM) 是一种分类模型, 该模型在特征空间中求解间隔最大的分类超平面。

关键词: 支持向量机; SVM; SMO; 矩阵运算; 矩阵求导; numpy; sklearn.

目录

| | | |
|----------|------------------------|----------|
| 1 | 数学推导与 python 实现 | 1 |
| 1.1 | 线性可分 | 1 |
| 1.2 | 公式推导 | 1 |

1 数学推导与 python 实现

1.1 线性可分

简单说明如下:

1.2 公式推导

过程表示如下:

$$\begin{aligned} \arg \max_{w_0} d &= \frac{y_0 \cdot (x_0^T \cdot w_0 + b_0)}{\|w_0\|} \\ \text{s.t. } \frac{y_i \cdot (x_i^T \cdot w_0 + b_0)}{\|w_0\|} &\geq d \end{aligned} \quad (1)$$

将 w_0 和 b_0 进行一定比例的缩放

$$\begin{aligned} w &= \frac{w_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \\ b &= \frac{b_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \end{aligned}$$

可以将 (1) 式化简为:

$$\begin{aligned} \arg \max_w d &= \frac{1}{\|w\|} \\ \iff \arg \min_w d &= \|w\| \\ \iff \arg \min_w d &= \frac{1}{2} w^T \cdot w \end{aligned} \quad (2)$$

$$\text{s.t. } y_i \cdot (x_i^T \cdot w + b) \geq 1 \quad (3)$$

将(2) 和 (3) 利用拉格朗日乘数法, 获得拉格朗日原始问题形式:

$$\begin{aligned} \arg \min_{w,b} \max_{\alpha} L(w,b,\alpha) &= \frac{1}{2} w^T \cdot w - \alpha^T \cdot (y \odot (X \cdot w + b) - \mathbf{1}) \\ &= \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \alpha^T \cdot \mathbf{1}^m \\ &= \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \mathbf{1}^T \cdot \alpha \end{aligned} \quad (4)$$

当满足 KKT 条件时, (4) 等价于拉格朗日对偶问题:

$$\arg \max_{\alpha} \min_{w,b} L(w,b,\alpha) = \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \mathbf{1}^T \cdot \alpha \quad (5)$$

首先求 L 以 w、b 为参数的极小值, 通过求微分得到偏导数形式。

$$\begin{aligned} dL &= \frac{1}{2} tr[(dw)^T \cdot w + w^T \cdot dw] - (\alpha \odot y)^T \cdot (X dw) \\ &\quad - (\alpha \odot y)^T \cdot db \\ &\quad - (d\alpha)^T \cdot (y \odot (X \cdot w + b) - \mathbf{1}) \\ &= tr[w^T dw - (X^T \cdot (\alpha \odot y))^T dw - (\alpha \odot y)^T \cdot db - (y \odot (X \cdot w + b) - \mathbf{1})^T d\alpha] \end{aligned}$$

从而得到 w、b 偏导数，并令偏导数为 0。

$$\begin{aligned}\frac{\partial L}{\partial w} &= w - X^T \cdot (\alpha \odot y) = \mathbf{0} \\ \frac{\partial L}{\partial b} &= -\alpha \odot y = \mathbf{0}\end{aligned}\tag{6}$$

推导出如下等式和约束：

$$w = X^T \cdot (\alpha \odot y)\tag{7}$$

$$\alpha \odot y = \mathbf{0}\tag{8}$$

将(7)式和 (8)式代入(5)式中，

$$\begin{aligned}\arg \max_{\alpha} L(w, b, \alpha) &= \frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\ &\quad - (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\ &\quad - (\alpha \odot y)^T \cdot b^m \\ &= -\frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + (\alpha \odot y^T) \cdot b \\ &= -\frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y)\end{aligned}$$

去除符号，将极大转换成极小形式：

$$\begin{aligned}\arg \min_{\alpha} L(w, b, \alpha) &= \frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\ \text{s.t. } &\alpha \odot y = \mathbf{0}\end{aligned}\tag{9}$$

加入软间隔参数，每个向量点距离分类超平面距离增加 ξ_i ，同时增加一个惩罚系数 C，代入(5)新形式如下：

$$L(w, b, \xi, \alpha, u) = \frac{1}{2}w^T \cdot w + C \cdot \xi^T \cdot \mathbf{1}^m - \alpha^T \cdot (y \odot (X \cdot w + b) - 1) - u^T \cdot \xi\tag{10}$$

求得对于 w、b、 ξ 的偏导并令其为 0：

$$\begin{aligned}\frac{\partial L}{\partial w} &= w - X^T \cdot (\alpha \odot y) = \mathbf{0} \\ \frac{\partial L}{\partial b} &= -\alpha \odot y = \mathbf{0} \\ \frac{\partial L}{\partial \xi} &= C - \alpha - u = \mathbf{0}\end{aligned}$$

代入 (10) 式中：

$$\begin{aligned}\arg \max_{\alpha} L(w, b, \xi, \alpha, u) &= -\frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + \mathbf{1}^m \cdot \alpha \\ \text{s.t. } &\alpha \odot y = \mathbf{0} \\ &C - \alpha - u = \mathbf{0} \\ &\alpha_i \geq 0 \\ &u_i \geq 0\end{aligned}\tag{11}$$

End!!