

SVM 的数学推导和 Python 实现

赵新锋

2021 年 7 月 12 日

摘要

支持向量机 (support vector machines, SVM) 是一种分类模型, 该模型在特征空间中求解间隔最大的分类超平面。

关键词: 支持向量机; SVM; SMO; 矩阵运算; 矩阵求导; numpy; sklearn.

目录

1	数学推导与 python 实现	1
1.1	分类超平面	1
1.2	公式推导	1

1 数学推导与 python 实现

1.1 分类超平面

简单说明如下：




图 1: SVM 线性可分

1.2 公式推导

过程表示如下：

$$\begin{aligned} \arg \max_{w_0} d &= \frac{y_0 \cdot (x_0^T \cdot w_0 + b_0)}{\|w_0\|} \\ \text{s.t. } \frac{y_i \cdot (x_i^T \cdot w_0 + b_0)}{\|w_0\|} &\geq d \end{aligned} \quad (1)$$

将 w_0 和 b_0 进行一定比例的缩放

$$\begin{aligned} w &= \frac{w_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \\ b &= \frac{b_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \end{aligned}$$

可以将 (1) 式化简为：

$$\begin{aligned} \arg \max_w d &= \frac{1}{\|w\|} \\ \iff \arg \min_w d &= \|w\| \\ \iff \arg \min_w d &= \frac{1}{2} w^T \cdot w \end{aligned} \quad (2)$$

$$\text{s.t. } y_i \cdot (x_i^T \cdot w + b) \geq 1 \quad (3)$$

将(2) 和 (3) 利用拉格朗日乘数法，获得拉格朗日原始问题形式：

$$\begin{aligned}
\arg \min_{w,b} \max_{\alpha} L(w,b,\alpha) &= \frac{1}{2} w^T \cdot w - \alpha^T \cdot (y \odot (X \cdot w + b) - 1) \\
&= \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \alpha^T \cdot \mathbf{1}^m \\
&= \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \mathbf{1}^T \cdot \alpha
\end{aligned} \tag{4}$$

当满足 KKT 条件时，(4) 等价于拉格朗日对偶问题：

$$\arg \max_{\alpha} \min_{w,b} L(w,b,\alpha) = \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \mathbf{1}^T \cdot \alpha \tag{5}$$

首先求 L 以 w、b 为参数的极小值，通过求微分得到偏导数形式。

$$\begin{aligned}
dL &= \frac{1}{2} tr[(dw)^T \cdot w + w^T \cdot dw] - (\alpha \odot y)^T \cdot (X dw) \\
&\quad - (\alpha \odot y)^T \cdot db \\
&\quad - (d\alpha)^T \cdot (y \odot (X \cdot w + b) - 1)] \\
&= tr[w^T dw - (X^T \cdot (\alpha \odot y))^T dw - (\alpha \odot y)^T \cdot db - (y \odot (X \cdot w + b) - 1)^T d\alpha]
\end{aligned}$$

从而得到 w、b 偏导数，并令偏导数为 0。

$$\begin{aligned}
\frac{\partial L}{\partial w} &= w - X^T \cdot (\alpha \odot y) = \mathbf{0} \\
\frac{\partial L}{\partial b} &= -\alpha \odot y = \mathbf{0}
\end{aligned} \tag{6}$$

推导出如下等式和约束：

$$w = X^T \cdot (\alpha \odot y) \tag{7}$$


$$\alpha \odot y = \mathbf{0} \tag{8}$$

将(7)式和 (8)式代入(5)式中，

$$\begin{aligned}
\arg \max_{\alpha} L(w,b,\alpha) &= \frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
&\quad - (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
&\quad - (\alpha \odot y)^T \cdot b^m \\
&= -\frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + (\alpha \odot y^T) \cdot b \\
&= -\frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y)
\end{aligned}$$

去除符号，将极大转换成极小形式：

$$\begin{aligned}
\arg \min_{\alpha} L(w,b,\alpha) &= \frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
\text{s.t. } &\alpha \odot y = \mathbf{0}
\end{aligned} \tag{9}$$



软间隔的支持向量

图 2: SVM 软间隔

加入软间隔参数, 每个向量点距离分类超平面距离增加 ξ_i , 同时增加一个惩罚系数 C, 代入(5)新形式如下:

$$L(w, b, \xi, \alpha, u) = \frac{1}{2}w^T \cdot w + C \cdot \xi^T \cdot \mathbf{1}^m - \alpha^T \cdot (y \odot (X \cdot w + b) - 1) - u^T \cdot \xi \quad (10)$$

求得对于 w、b、 ξ 的偏导并令其为 0:

$$\begin{aligned} \frac{\partial L}{\partial w} &= w - X^T \cdot (\alpha \odot y) = \mathbf{0} \\ \frac{\partial L}{\partial b} &= -\alpha \odot y = \mathbf{0} \\ \frac{\partial L}{\partial \xi} &= C - \alpha - u = \mathbf{0} \end{aligned}$$

代入 (10) 式中:

$$\begin{aligned} \arg \max_{\alpha} L(w, b, \xi, \alpha, u) &= -\frac{1}{2}(\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + \mathbf{1}^m \cdot \alpha \\ \text{s.t. } \alpha \odot y &= \mathbf{0} \\ C - \alpha - u &= \mathbf{0} \\ \alpha_i &\geq 0 \\ u_i &\geq 0 \end{aligned} \quad (11)$$

End!!