

# SVM 的数学推导和 Python 实现

赵新锋

2021 年 7 月 12 日

## 摘要

支持向量机 (support vector machines, SVM) 是一种分类模型, 该模型在特征空间中求解间隔最大的分类超平面。

**关键词:** 支持向量机; SVM; SMO; 矩阵运算; 矩阵求导; numpy; sklearn.

# 目录

<b>1</b>	<b>数学推导与 python 实现</b>	<b>1</b>
1.1	线性可分 . . . . .	1
1.2	公式推导 . . . . .	3

# 1 数学推导与 python 实现

## 1.1 线性可分

三层网络简单说明如下：

- 输入层，不做处理，只是输入数据
- 隐藏层，单元数为  $n_h$  我们就以 RELU 为激活函数，另外一个常用的是 sigmoid，我们把激活函数封装成一个类，可以随时替换
- 输出层为一个单元，由于是二分类，我们就用 sigmoid 拟合对应类 1 的概率




图 1: 神经网络示意图

- $X$  表示输入样本向量矩阵,  $Y$  表示样本集的期望输出标记 (有可能是 0/1 标记的向量, 有可能是 onehot 的矩阵), 本文示例由于是二分类, 那么  $Y$  的每个元素要么是 0 要么是 1,  $Y$  是  $m$  个元素的向量, 但是在运算中为了通用将其转换为  $m \times 1$  的矩阵。
- $m$  为样本数量,  $n$  为样本向量的维度。

- 激活函数用  $f$  表示，隐藏层激活函数  $f_h$  使用 RELU 函数:  $f_h(x) = \max(0, x)$ ，输出层  $f_o$  为 sigmoid 函数，输出为 1 类的概率  $f_o(x) = \frac{1}{1+\exp(-x)}$
- 隐藏层输出为  $Y_h$ ，输出层的输出为  $Y_o$
- 隐藏层单元的参数为  $w_h$ ， $N_h$  个隐藏层单元的参数矩阵为  $W_h$ ，输出层单元的参数为  $w_o$ ， $N_o$  个输出层单元的参数矩阵为  $W_o$ 。
- 虽然本文使用二分类即输出单元为 1 个，但是仍然使用矩阵  $Y_o$  和  $W_o$  表示，从而使得算法是通用的，改成 onehot+softmax 方式的多分类，也是适用的。
- 从输入到输出的公式:  $Y_o = f_o(f_h(X \cdot W_h) \cdot W_o)$
- 注：这里的线性变换  $X \cdot W_h$  并没有使用偏置，通过在  $X$  增加一个全 1 的列，达到同样的效果。

## 1.2 公式推导

单个样本的运算过程表示如下：

$$\begin{aligned}
& \arg \max_{w_0} d = \frac{y_0 \cdot (x_0^T \cdot w_0 + b_0)}{\|w_0\|} \\
& \text{s.t. } \frac{y_i \cdot (x_i^T \cdot w_0 + b_0)}{\|w_0\|} \geq d \\
& w = \frac{w_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \\
& b = \frac{b_0}{y_0 \cdot (x_0^T \cdot w_0 + b_0)} \\
& \arg \max_w d = \frac{1}{\|w\|} \iff \arg \min_w \|w\| \\
& \text{s.t. } y_i \cdot (x_i^T \cdot w + b) \geq 1 \\
& \arg \min_{w,b} L(w, b, \alpha) = \frac{1}{2} w^T \cdot w - \alpha^T \cdot (y \odot (X \cdot w + b) - 1) \\
& = \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \alpha^T \cdot \mathbf{1}^m \\
& = \frac{1}{2} w^T \cdot w - (\alpha \odot y)^T \cdot (X \cdot w + b) - \mathbf{1}^T \cdot \alpha \\
& dL = \frac{1}{2} ((dw)^T \cdot w + w^T \cdot dw) - (\alpha \odot y)^T \cdot (X dw) \\
& \quad - (\alpha \odot y)^T \cdot db \\
& \quad - (d\alpha)^T \cdot (y \odot (X \cdot w + b) - 1) \\
& = w^T dw - (X^T \cdot (\alpha \odot y))^T dw - (\alpha \odot y)^T \cdot db - (y \odot (X \cdot w + b) - 1)^T d\alpha \\
& \frac{\partial L}{\partial w} = w - X^T \cdot (\alpha \odot y) \\
& \frac{\partial L}{\partial b} = -\alpha \odot y \\
& \iff \\
& w = X^T \cdot (\alpha \odot y) \\
& \alpha \odot y = \mathbf{0} \\
& \arg \max_{\alpha} L(w, b, \alpha) = \frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
& \quad - (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
& \quad - (\alpha \odot y)^T \cdot b^m \\
& = -\frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + (\alpha \odot y^T) \cdot b \\
& = -\frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
& \iff \arg \min_{\alpha} L(w, b, \alpha) = \frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) \\
& \text{s.t. } \alpha \odot y = \mathbf{0}
\end{aligned}$$

(1)

$$\begin{aligned}
L(w, b, \alpha, u) &= \frac{1}{2} w^T \cdot w + C \cdot \xi^T \cdot \mathbf{1}^m - \alpha^T \cdot (y \odot (X \cdot w + b) - 1) - u^T \cdot \xi \\
\frac{\partial L}{\partial w} &= w - X^T \cdot (\alpha \odot y) \\
\frac{\partial L}{\partial b} &= -\alpha \odot y \\
\frac{\partial L}{\partial \xi} &= C - \alpha - u \\
\Longleftrightarrow L(w, b, \xi, \alpha, u) &= -\frac{1}{2} (\alpha \odot y)^T \cdot X^T \cdot X \cdot (\alpha \odot y) + \mathbf{1}^m \cdot \alpha \\
\text{s.t. } \alpha \odot y &= \mathbf{0} \\
C - \alpha - u &= \mathbf{0} \\
\alpha_i &\geq 0 \\
u_i &\geq 0
\end{aligned}$$

End!!